

Análisis de regresión

Clase 2

Isabel Ramírez

Universidad Nacional

2026

Regresión Lineal Simple (RLS)

- Se desea modelar la relación de tendencia entre un par de variables (X , Y).
- Muchas veces se cuenta con datos observacionales sobre estas variables, obtenidos bajo situaciones no controladas estrictamente.
- Posiblemente, no hubo replicación de las condiciones observadas.
- Bajo estas circunstancias lo más conveniente es el método de mínimos cuadrados (MCO).

Nomenclatura del modelo de RLS

En el modelo teórico:

- Y : Variable respuesta o dependiente.
- X : Variable predictora, independiente o regresora.
- E : Error aleatorio
- β_0, β_1 : Parámetros de la regresión. β_0 es el intercepto y β_1 la pendiente de la línea recta.
- $\mu_{Y|X}$: Valor esperado condicional de Y dado X , es decir, $E[Y|X]$

En el modelo estimado:

- $\hat{\beta}_0$: Estimador del parámetro β_0 .
- $\hat{\beta}_1$: Estimador del parámetro β_1 .
- $\hat{E}$: Variable aleatoria correspondiendo al residual del modelo ajustado. Es una estimación del error aleatorio.
- $\hat{Y}$: Respuesta estimada. Variable aleatoria que representa la estimación de $\mu_{Y|X}$

Función de medias con forma lineal (MRLS)




Figura: Recta en el modelo de regresión lineal simple como la función de la media condicional de $Y|x$. En este ejemplo se ha asumido que $Y|x \sim N(62 + 3.5x, \sigma^2)$, luego, la recta de regresión corresponde a $E[Y|x] = 62 + 3.5x$ y en cada nivel de x se tiene la misma varianza para Y alrededor de la respectiva media condicional.

Modelo de Regresión Lineal Simple (MRLS)

Con n pares (X_i, Y_i) , $i = 1, 2, \dots, n$:

$$Y_i|X_i = \beta_0 + \beta_1 X_i + E_i$$

donde:

- E_i es el error aleatorio y $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$.
- β_j , $j = 0, 1$: Parámetros de la regresión.
- $E[Y|X_i] = \beta_0 + \beta_1 X_i$

Por simplicidad escribimos,

$$Y_i = \beta_0 + \beta_1 X_i + E_i, \quad E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \quad i = 1, \dots, n$$

Los errores $E_i = Y_i - (\beta_0 + \beta_1 X_i)$ no son observables dado que los parámetros β_0 y β_1 son desconocidos y deben estimarse.

Características del MRLS

Bajo los supuestos de normalidad, independencia y varianza constante de los errores (Kutner et. al., 2005),

- Y es una variable aleatoria cuyos valores se observan mediante la selección de los valores de las variables predictoras en un espacio de valores de interés.
- La variable predictora no es considerada como variables aleatorias. Sin embargo si esto último no se cumple, el método de mínimos cuadrados ordinarios puede seguir siendo válido si los errores en los valores de las variables X son pequeños en comparación con los errores aleatorios.
- Si los datos observados no son una muestra representativa no es apropiado realizar inferencias (extrapolaciones) en un rango de los datos por fuera del considerado.
- El modelo de regresión es lineal en los parámetros.

Características del MRLS

- Los errores aleatorios $E_i \sim N(0, \sigma^2)$, $i = 1, 2, \dots, n$ y además, son estadísticamente independientes. En consecuencia, los valores de la variable respuesta también son estadísticamente independientes y por tanto no correlacionados.
- La varianza de los errores aleatorios es σ^2 , $\forall i, i = 1, 2, \dots, n$ pero desconocida.
- Los Y_i (o sea $Y|X_i$) son variables aleatorias normales e independientes, pero no son idénticamente distribuidos, pues no tienen misma media aunque sí tienen misma varianza igual a σ^2 :

$$Y|X_i \stackrel{\text{ind}}{\sim} N(\beta_0 + \beta_1 X_i, \sigma^2)$$

Significado de los coeficientes de regresión

- β_0 : intercepto, representará la respuesta media de Y cuando en el conjunto de observaciones sobre la variable predictora se incluye la coordenada $x = 0$, de lo contrario, si tal coordenada no es observada, entonces β_0 no será interpretable.
- β_1 : representa el cambio en la media de Y dado un cambio unitario en X .

Tipos de variables predictoras

- Cuantitativas, caso en el cual se supone se miden sin error (o el error es despreciable).
- Cualitativas o categóricas, en este caso su manejo en el modelo se realiza a través de la definición de variables indicadoras, las cuales toman valores de 0 ó 1. Por ejemplo, suponga un modelo de regresión para el gasto mensual por familia en actividades recreativas, se tiene entre las variables predictoras la zona de la ciudad donde habita la familia, dividida en cinco niveles, luego, para cada nivel se define una variable indicadora de la siguiente forma:

$$I_j = \begin{cases} 1 & \text{familia habita en zona } j, j = 1, 2, \dots, 5 \\ 0 & \text{en otro caso} \end{cases}$$

En general, una variable predictora cualitativa con c clases o niveles se representa mediante $c - 1$ variables indicadoras, puesto que cuando en una observación dada, $c - 1$ indicadoras son iguales a cero, entonces la variable cualitativa se haya en la clase restante.

Estimación por Mínimos Cuadrados (MCO)

Con n pares (x_i, y_i) de observaciones se encuentran los estimadores de β_0 y β_1 que minimizan la suma de los cuadrados de los errores,

$$S(\beta_0, \beta_1) = \sum_{i=1}^n [Y_i - (\beta_0 + \beta_1 X_i)]^2 = \sum_{i=1}^n E_i^2.$$

Los estimadores resultantes son:

$$\hat{\beta}_0 = \bar{y} - \beta_1 \bar{x},$$
$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Estimación del MRLS

Estimación de máxima verosimilitud

Puede mostrarse que el método de MCO produce los mejores estimadores lineales insesgados para los parámetros de la línea de regresión y puede ser usado para la estimación de los parámetros del MRLS sin consideraciones distribucionales sobre los errores. Sin embargo, para poder aplicar pruebas de hipótesis y construir intervalos de confianza y otro tipo de inferencias, es necesario realizar y validar tales supuestos. Considerando para los errores del MRLS los supuestos de normalidad, independencia y varianza constante, podemos usar el método de estimación de máxima verosimilitud (MLE) de los parámetros $\beta_0, \beta_1, \sigma^2$.

Estimación del MRLS

La función de verosimilitud $L(\beta_0, \beta_1, \sigma^2 | \mathbf{y}, \mathbf{x})$ es,

$$\begin{aligned} L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) &= f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y_i - \beta_0 - \beta_1 x_i)^2 \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} S(\beta_0, \beta_1) \right\}, \end{aligned}$$

El objetivo es hallar β_0 , β_1 y σ^2 que maximicen a $L(\beta_0, \beta_1, \sigma^2 | \mathbf{y}, \mathbf{x})$, o equivalentemente al logaritmo natural de L (log-verosimilitud).

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} S(\beta_0, \beta_1)$$

Estimadores MLE vs. estimadores MCO

- Los estimadores de MLE: $\tilde{\beta}_0$ y $\tilde{\beta}_1$ son iguales a los estimadores MCO $\hat{\beta}_0$ y $\hat{\beta}_1$, respectivamente.
- La diferencia entre los dos métodos se da en que en el estimador de la varianza σ^2 .
- Cuando alguno de los supuestos sobre los errores no es válido, hay que buscar soluciones alternativas: Transformaciones, modelos lineales generalizados, métodos no paramétricos, entre otros.

Respuesta estimada, residuos, estimador de varianza

- La respuesta ajustada es igual a

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

- Los residuos son:

$$\hat{\varepsilon}_i = y_i - \hat{y}_i$$

- Bajo el supuesto de $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, el estimador insesgado de la varianza es

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2 = \frac{SSE}{n-2} = MSE$$

- Bajo el supuesto de $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, el estimador MLE de la varianza es

$$\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2 = \frac{SSE}{n},$$

el cual no es un estimador insesgado de la varianza pues $E(\tilde{\sigma}^2) = \left(\frac{n-2}{n}\right) \sigma^2$

Propiedades de los estimadores

Bajo los supuestos sobre los errores, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$: los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$, satisfacen las siguientes propiedades:

- Son estimadores insesgados de β_0 y β_1 , respectivamente. Por lo tanto $E(\hat{\beta}_0) = \beta_0$ y $E(\hat{\beta}_1) = \beta_1$.
- Se pueden escribir como una combinación lineal de la respuesta Y , así $\hat{\beta}_0 = \sum_{i=1}^n m_i Y_i$ y $\hat{\beta}_1 = \sum_{i=1}^n c_i Y_i$, donde $c_i = \frac{x_i - \bar{x}}{S_{xx}}$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ y $m_i = \frac{1}{n} - \bar{x}c_i$.
- $V(\hat{\beta}_0) = \frac{\sum_{i=1}^n x_i^2}{nS_{xx}} \sigma^2$ y $V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$.
- $\hat{\beta}_j \sim N(\beta_j, V(\hat{\beta}_j))$, $j = 0, 1$
- Se tiene que σ^2 es desconocida, por lo tanto $\widehat{V(\hat{\beta}_0)} = \frac{\sum_{i=1}^n x_i^2}{nS_{xx}} MSE$ y $\widehat{V(\hat{\beta}_1)} = \frac{MSE}{S_{xx}}$.
- $T_0 = \frac{\hat{\beta}_j - \beta_j}{\sqrt{V(\hat{\beta}_j)}} \sim t_{n-2}$

Inferencias sobre los parámetros - Pruebas de hipótesis

Test bilateral	Estadístico de prueba	Criterio de rechazo
$H_0 : \beta_j = \beta_{j0}$ $H_1 : \beta_j \neq \beta_{j0}$	$T_0 = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{V(\hat{\beta}_j)}} \sim t_{n-2}$	con nivel α : si $T_0 > t_{\alpha/2, n-2}$ con valor P, si: $P(t_{n-2} > T_0)$ es pequeño.

Tests unilaterales	Estadístico de prueba	Criterio de rechazo
$H_0 : \beta_j = \beta_{j0}$ $H_1 : \beta_j > \beta_{j0}$	$T_0 = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{V(\hat{\beta}_j)}} \sim t_{n-2}$	con nivel α : si $T_0 > t_{\alpha, n-2}$ con valor P, si: $P(t_{n-2} > T_0)$ es pequeño.

$H_0 : \beta_j = \beta_{j0}$ $H_1 : \beta_j < \beta_{j0}$	$T_0 = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{V(\hat{\beta}_j)}} \sim t_{n-2}$	con nivel α : si $T_0 < -t_{\alpha, n-2}$ con valor P, si: $P(t_{n-2} < T_0)$ es pequeño.
--	---	--

Inferencias sobre los parámetros - Intervalos de confianza

La estimación por intervalo de confianza al $(1-\alpha)100\%$ es:

$$\hat{\beta}_j \pm t_{\alpha/2, n-2} \times \sqrt{\widehat{V(\hat{\beta}_j)}}$$

- Devore, J. L. (2016). Probabilidad y Estadística para Ingeniería y Ciencias, 9a. ed.. Cengage Learning, México.
- Kutner, M. H., Natchtsheim, C. J., Neter, J. and Li, W., (2005). Applied Linear Statistical Models, 5th. ed. McGraw-Hill Irwing, NewYork.