

Análisis de regresión

Clase 3

Isabel Ramírez

Universidad Nacional

2026

Inferencias sobre la respuesta media y valores futuros

- Veremos que tanto la estimación de la respuesta media como la predicción cuando $X = x_0$, son

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

donde los parámetros estimados han sido obtenidos con n pares de observaciones muestrales (x_i, y_i) , $i = 1, \dots, n$.

- Cuando consideramos a $\hat{y}_0$ como la estimación de $\mu_{y|x_0}$, estamos apuntando a la estimación del valor en el cual se espera que la distribución de la respuesta tienda a centrarse en repetidos ensayos aleatorios en los que X se ha fijado en x_0 .
- Por otro lado, cuando consideramos $\hat{y}_0$ como la predicción de una nueva observación de la respuesta cuando $X = x_0$, apuntamos al valor que pudiera ocurrir para $Y|x_0$ en un nuevo ensayo, independiente de aquellos ensayos con los cuales se realizó el análisis de regresión. Por supuesto se asume que el modelo de regresión aplicado a los datos muestrales continúa siendo apropiado para la nueva observación (Kutner et. al., 2005).

Inferencias sobre la respuesta media en el punto x_0

- Respuesta media estimada en x_0 : $\hat{\mu}_{Y|x_0} = \hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$
- Es un estimador insesgado de $\mu_{Y|x_0}$, por lo tanto

$$E[\hat{\mu}_{Y|x_0}] = \beta_0 + \beta_1 x_0 = \mu_{Y|x_0}$$
- Su varianza es $\text{Var}[\hat{Y}_0] = \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] \sigma^2 = h_{00} \sigma^2$
- Desde que $\hat{\mu}_{Y|x_0}$ es una transformación lineal sobre $\hat{\beta}_0$ y $\hat{\beta}_1$, entonces

$$\hat{\mu}_{Y|x_0} \sim N(\beta_0 + \beta_1 x_0, h_{00} \sigma^2)$$

- Note que un estimador insesgado de $\text{Var}[\hat{\mu}_{Y|x_0}]$, es

$$\widehat{\text{Var}}[\hat{\mu}_{Y|x_0}] = h_{00} \text{MSE}.$$

Inferencias sobre la respuesta media en el punto x_0

Intervalo de confianza de nivel $(1 - \alpha)100\%$ para la respuesta media en el punto x_0 ,

$$\hat{Y}_0 \pm t_{\alpha/2, n-2} \sqrt{\text{MSE} h_{00}},$$

Hipótesis H_0	Estadístico de prueba
$H_0: \mu_{Y x_0} = c$	$T_0 = \frac{\hat{Y}_0 - c}{\sqrt{\text{MSE} h_{00}}}$
Hipótesis H_1	Criterio de rechazo de H_0
$H_1: \mu_{Y x_0} \neq c$	con nivel α : si $ T_0 > t_{\alpha/2, n-2}$ con valor P: si $ t_{n-2} > T_0 $ es pequeño.
$H_1: \mu_{Y x_0} > c$	con nivel α : si $T_0 > t_{\alpha, n-2}$ con valor P: si $t_{n-2} > T_0$ es pequeño.
$H_1: \mu_{Y x_0} < c$	con nivel α : si $T_0 < -t_{\alpha, n-2}$ con valor P: si $t_{n-2} < T_0$ es pequeño.

Inferencias sobre la predicción en el punto x_0

- La predicción (respuesta futura) en x_0 : $\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$
- La predicción $\hat{Y}_0$ es estadísticamente independiente de Y_0 , por tanto $\text{Cov}(Y_0, \hat{Y}_0) = 0$
- El error de predicción, $Y_0 - \hat{Y}_0$, cumple que:
 - Su media es cero: $E[Y_0 - \hat{Y}_0] = 0$.
 - Su varianza es $\text{Var}[Y_0 - \hat{Y}_0] = \text{Var}[Y_0] + \text{Var}[\hat{Y}_0] = \sigma^2 + h_{00}\sigma^2$.
 - Su distribución es:


$$Y_0 - \hat{Y}_0 \sim N(0, \sigma^2(1 + h_{00})).$$

- Intervalo de predicción al $(1 - \alpha)100\%$ es,

$$\hat{Y}_0 \pm t_{\alpha/2, n-2} \sqrt{\text{MSE} [1 + h_{00}]}$$

No se recomienda realizar extrapolaciones por fuera del rango de variación observado en la variable X , pues es posible que por fuera de éste, la relación estadística formulada no resulte válida.

Inferencias sobre respuesta media y predicción



Sumas de cuadrados

- Suma de cuadrados de residuos (SSE)

$$SSE = \sum_{i=1}^n \hat{\varepsilon}_i^2 = (y_i - \hat{y}_i)^2.$$

Se interpreta como *la variabilidad de la respuesta que no es explicada por el modelo de regresión*. Se tiene que $\frac{SSE}{\sigma^2} \sim \chi_{n-2}^2$.

- Suma de cuadrados de totales (SST)

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

Se define como la *variabilidad total observada en la variable respuesta*.

- Sumas de cuadrados de la regresión (SSR)

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

La SSR representa la *variabilidad observada en la variable respuesta que es explicada por el modelo de regresión*. Se tiene que $\frac{SSR}{\sigma^2} \sim \chi_1^2$ bajo $H_0 : \beta_1 = 0$.

Descomposición ANOVA de la variabilidad total de la respuesta

La descomposición ANOVA o descomposición de la variabilidad total observada en la respuesta consiste en la siguiente identidad,

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{\text{Variabilidad total (SST)}} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{\text{Variabilidad explicada (SSR)}} + \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{Variabilidad no explicada (SSE)}}$$

En virtud de la anterior igualdad, podemos también establecer la siguiente identidad para los grados de libertad (g.l) de las sumas de cuadrados:

$$\underbrace{\text{g.l (SST)}}_{n-1} = \underbrace{\text{g.l (SSR)}}_1 + \underbrace{\text{g.l (SSE)}}_{n-2}.$$

Test ANOVA: Prueba de la significancia del MRLM

Se evalúa la significancia del MRLS: *si la porción de la variabilidad observada en la respuesta que es explicada por el MRLS es significativa*. Esto es realizado mediante el test ANOVA, el cual propone el siguiente juego de hipótesis:

$$H_0 : \beta_1 = 0;$$

$$H_1 : \beta_1 \neq 0.$$

Estadístico de prueba

$$F_0 = \frac{\frac{\frac{SSR}{\sigma^2}}{1}}{\frac{\frac{SSE}{\sigma^2}}{n-2}} = \frac{MSR}{MSE} \sim f_{1,n-2}.$$

Test ANOVA: Prueba de la significancia del MRLM

Cuadro: Tabla ANOVA del modelo de regresión lineal múltiple

Fuente	SC	g.l	CM	Estadístico F_0	Valor P
Regresión	SSR	1	$MSR = SSR/1$	MSR/MSE	$f_{k,n-2} > F_0$
Error	SSE	$n - 2$	$MSE = SSE / (n - 2)$		
Total	SST	$n - 1$	$MST = SST / (n - 1)$		
Fórmulas					
$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ $SST = \sum_{i=1}^n (y_i - \bar{y})^2,$					


Coeficiente de determinación Múltiple ó R^2

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$


Se puede interpretar como *la proporción de la variabilidad total observada en la variable respuesta, que es explicada por la relación lineal con las variables predictoras consideradas*. Kutner et. al., 2005, lista como los tres errores de interpretación más comunes del R^2 ,

- Creer que un R^2 alto indica que el modelo puede hacer predicciones útiles.
- Creer que un R^2 alto indica que la superficie de regresión ajustada tiene buen ajuste
- Creer que un R^2 cercano a cero indica que Y no está relacionada con las variables X_j .

Coeficiente de determinación Múltiple ó R^2




(a)




(b)

Figura: (c) la verdadera relación estadística es lineal: $\mu_{Y|x} = 650 + 2x$ y el ajuste del MRLS arroja un R^2 cercano a 1; (d) La verdadera relación no es lineal: $\mu_{Y|x} = 30000 + 2x + 0,2x^2$ aunque el ajuste del MRLS arroja R^2 cercano a 1;

Coeficiente de determinación Múltiple ó R^2



(a)



(b)

Figura: (a) La verdadera relación no es lineal: $\mu_{Y|X} = 92500 - 100x + 0,2x^2$ y el ajuste del MRLS produce un R^2 de casi cero; (b) El verdadero modelo es $Y_i = 5000 + E_i$, $E_i \stackrel{iid}{\sim} N(0, 10000)$, es decir, no hay algún tipo de asociación estadística de Y con X , sin embargo, se ajustó el MRLS asumiendo que $\mu_{Y|X} = \beta_0 + \beta_1 x$, y su ajuste da un R^2 pequeño, como era de esperarse bajo estas circunstancias.

Coeficiente de correlación múltiple y el R^2_{adj}

- $R = \sqrt{R^2}$ es llamado el coeficiente de correlación múltiple, puesto que mide la relación entre la variable respuesta Y y un conjunto de predictores $X_1, X_2, \dots, X_k$.
- La calidad del ajuste se puede medir con el R^2 ajustado, R^2_{adj} . Es una medida que tiene en cuenta la magnitud del modelo, es decir el número de predictores presentes, y que penaliza al modelo en virtud de los grados de libertad en la estimación de la varianza.

$$R^2_{adj} = 1 - \frac{\text{MSE}}{\text{MST}} = 1 - \frac{n-1}{n-k-1} (1 - R^2).$$

El R^2_{adj} puede decrecer con el ingreso de nuevas variables predictoras al modelo de regresión, incluso, $R^2_{adj} \in (-\infty, 1]$, mientras que $R^2 \in [0, 1]$, *por ello el R^2_{adj} no puede interpretarse como la proporción de la variabilidad observada en la respuesta que es explicada por el modelo*. Como medida de ajuste, entre modelos que ajusten a la respuesta en la misma escala, es mejor aquél cuyo R^2_{adj} sea el mayor.

- Montgomery, D. C., Peck, E. A. and Vining, G. G. (2021). Introduction to Linear Regression Analysis, 6th ed. Wiley, New Jersey.
- Kutner, M. H., Natchtsheim, C. J., Neter, J. and Li, W., (2005). Applied Linear Statistical Models, 5th. ed. McGraw-Hill Irwing, NewYork.