

Análisis de regresión

Clase 4

Isabel Ramírez

Universidad Nacional

2026


Diagnósticos en el MRLS

Tipos de Diagnóstico


- Para la variable predictora
 - observaciones extremas en X que puedan influenciar el ajuste de regresión. Realizar un análisis descriptivo: box plots, diagramas de puntos.
 - Patrones temporales en los valores de la variable X mediante un gráfico de X vs. tiempo o algún otro índice de ordenación.
- Para el modelo
 - La función de regresión no es lineal.
 - Los errores no tienen varianza constante.
 - Los errores no son independientes.
 - Los errores no son normales.
 - El modelo ajusta bien pero unas pocas observaciones son outliers o atípicas.
 - Una o varias variables predictoras han sido omitidas en el modelo.

Chequeo sobre la forma del modelo

Chequeo de la linealidad antes del ajuste del modelo: Hacer chequeo en el análisis descriptivo. Chequear esto cuando solo hay una variable explicatoria es fácil mediante el gráfico de dispersión.



(a)



(b)

Figura: (a) Gráfico de dispersión cuando un MRLS puede ser adecuado; (b) Gráfico de dispersión cuando un MRLS no es adecuado

Chequeo sobre la forma del modelo


Chequeo de la linealidad después del ajuste del modelo:

- El gráfico de y_i vs. $\hat{y}_i$, si el modelo es correcto en su especificación, se espera una relación lineal positiva entre estas dos variables.
- El gráfico de $\hat{E}_i$ vs. $\hat{y}_i$, el cual debe mostrar una nube de puntos centrada verticalmente en cero y libre de patrones de tendencia. Bajo los supuestos sobre los errores del MRLS,


$$\text{Corr}(\hat{E}_i, \hat{Y}_j) = 0, \forall i, j,$$

- El gráfico de residuos vs. X , si el modelo introduce de forma apropiada al predictor en la ecuación, no se espera algún patrón en estos gráficos. Tendencias en este gráfico es indicativo de desviaciones de la linealidad asumida entre Y y X .

Chequeo de la linealidad después del ajuste del modelo



(a)



(b)

Figura: (a) Gráfico esperado de residuos vs. un predictor x cuando en el modelo no hay anomalías; (b) Gráfico esperado de residuos vs. $\hat{y}$ cuando en el modelo no hay anomalías.

Chequeo de la linealidad después del ajuste del modelo




Figura: Ejemplo del caso donde el modelo lineal entre y y x no es adecuado, pero la varianza es constante, donde (a) gráfico de dispersión con recta ajustada, (b) residuos vs. x y (c) residuos vs. $\hat{y}$.

Chequeo de la linealidad después del ajuste del modelo






Figura: Ejemplo del caso donde el modelo lineal entre y y x no es adecuado, ni la varianza es constante, donde (a) gráfico de dispersión con recta ajustada (b) residuos vs. x y (c) residuos vs. $\hat{y}$.


Chequeo de la linealidad después del ajuste del modelo



(a)




(b)




(c)

Figura: Patrón donde el modelo lineal es correcto pero la varianza no es constante. Patrón de embudo: (a) gráfico de dispersión con recta ajustada; (b) residuos vs. x ; (c) residuos vs. $\hat{y}$.


Chequeo de la linealidad después del ajuste del modelo



(a)




(b)




(c)

Figura: Patrón donde el modelo lineal es correcto pero la varianza no es constante. Patrón de balón de fútbol americano: (a) gráfico de dispersión con recta ajustada; (b) residuos vs. x ; (c) residuos vs. $\hat{y}$.


Chequeo de la linealidad después del ajuste del modelo



(a)



(b)



(c)

Figura: Patrones donde el modelo lineal es correcto pero la varianza no es constante. Patrón de embudo no lineal: (a) gráfico de dispersión con recta ajustada; (b) residuos vs. x ; (c) residuos vs. $\hat{y}$.

Chequeo de la linealidad después del ajuste del modelo






Figura: Ejemplo del caso donde al modelo le falta el efecto lineal de una variable predictora omitida: El modelo considerado es $Y_i = \beta_0 + \beta_1 x_1 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. (a) Gráfico de dispersión con recta ajustada de y vs. x_1 ; (b) gráfico de dispersión de y vs. x_2 , muestra que también hay relación lineal con x_2 (predictor omitido); (c) residuos vs. x_1 ; (d) residuos vs. $\hat{y}$; (e) residuos vs. x_2 , aquí vemos también evidencia de que hace falta incluir a x_2 en el modelo lineal.

Test de carencia de ajuste



(a)



(b)

Figura: Ejemplificando la idea de la carencia de ajuste en el contexto de la RLS. En (a), bajo el MRLS, $E[Y|X] = \beta_0 + \beta_1 X$; sin embargo, si $E[Y|X] = f(X)$ con $f(x)$ una función no lineal en x , como por ejemplo en (b), entonces $E[Y|X] \neq \beta_0 + \beta_1 X$ y en consecuencia el MRLS tendría **carencia de ajuste**.

En general, la carencia de ajuste de un modelo de regresión es cuando la función de regresión propuesta en el modelo no representa correctamente a la media de Y dado X , es decir a $E[Y|X]$.

Test de carencia de ajuste

- En el test de carencia de ajuste se compara la $E[Y|X]$ que define el MRLS vs. la $E[Y|X]$ del modelo denominado modelo lineal general.
- El modelo lineal general tiene las siguientes características:
 - Mide las diferencias entre las medias de Y según diferentes niveles de X .
 - Trata a X como un factor o variable cualitativa, cuyos niveles son los valores diferentes preseleccionados para X .
 - Se conoce en el contexto de diseño de experimentos como modelo ANOVA de un factor de efectos fijos.
- Para el test se supone que:
 - Se han predefinido k niveles (valores) diferentes de X : $x_i, i = 1, \dots, k$.
 - En cada nivel x_i se observan de forma independiente (en un diseño muestral completamente aleatorizado) n_i valores de la respuesta.
 - Se puede estimar de forma insesgada a μ_i : la media de Y en el nivel x_i de X , a través del promedio muestral de los respectivos n_i valores observados y que denotaremos por $\bar{Y}_{i\bullet}$.
 - La varianza de la respuesta en cada nivel x_i es la misma e igual a σ^2 , es decir, $\text{Var}[Y_{ij}] = \sigma^2, \forall i, j$.

Test de carencia de ajuste

El test asume que los valores de Y dado X son: independientes, se distribuyen en forma normal y tienen varianza constante.

Se requiere que en uno o más valores de X haya más de una observación de Y o réplicas. Usaremos la siguiente notación:

- Y_{ij} , la respuesta j -ésima en el i -ésimo nivel de X ;
- x_i , i -ésimo nivel de X ; $i = 1, \dots, k$;
- n_i , número de observaciones de Y tomadas en el i -ésimo nivel de X . Por tanto, el total de observaciones n corresponde a $n = \sum_{i=1}^k n_i$. El test define el modelo lineal general que corresponde a

$$Y_{ij} = \mu_i + E_{ij}, \quad E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad i = 1, 2, \dots, k, \quad j = 1, 2, \dots, n_i$$

donde $E[Y_{ij}] = \mu_i$.

- La suma de cuadrados de residuales de este ajuste es denominada la SSPE o suma de cuadrados de error puro y con $n - k$ grados de libertad,

$$\text{SSPE} = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i\bullet})^2.$$

Test de carencia de ajuste

Fuente	SC	gl	CM	F calculada	Valor P
Regresión	SSR	1	$MSR = \frac{SSR}{1}$	$F_{0,reg} = \frac{MSR}{MSE}$	$f_{1,n-2} > F_{0,reg}$
LOF	SSLOF	$k - 2$	$MSLOF = \frac{SSLOF}{k-2}$	$F_{0,LOF} = \frac{MSLOF}{MSPE}$	$f_{k-2,n-k} > F_{0,LOF}$
Error Puro	SSPE	$n - k$	$MSPE = \frac{SSPE}{n-k}$		
Error	SSE	$n - 2$	$MSE = \frac{SSE}{n-2}$		
Total	SST	$n - 1$	$MST = \frac{SST}{n-1}$		
SC: Suma de cuadrados, CM: cuadrado medio y gl: grados de libertad.					

Se quiere probar que,

$$H_0 : \mu_i = \beta_0 + \beta_1 x_i, \text{ no hay carencia de ajuste}$$

$$H_1 : \mu_i \neq \beta_0 + \beta_1 x_i.$$

Test de carencia de ajuste

¿Qué hacer si hay carencia de ajuste?

- Desarrollar un modelo más apropiado (tal vez un modelo de regresión no lineal).
- Transformar las variables X y/o Y para tener un MRLS en los datos transformados.
- Regresión no paramétrica, para explorar y/o confirmar la forma de la función de regresión.