

Análisis de regresión

Clase 5

Isabel Ramírez

Universidad Nacional

2026

Chequeo sobre los supuestos en los errores

Al modelo de regresión se ha impuesto las siguientes tres condiciones sobre el término de error:

- Los errores son variables aleatorias normales de media cero
- Los errores se distribuyen con igual varianza
- Los errores son mutuamente independientes

Supuesto de varianza constante, Tests de homocedasticidad

Suponga el modelo $Y_i = \beta_0 + \beta_1 x_i + E_i$, con $E_i \stackrel{\text{ind.}}{\sim} N(0, \sigma_i^2)$. Se desea probar la siguiente hipótesis

$$H_0 : \sigma_i^2 = \sigma^2 \quad \text{vs.} \quad H_1 : \sigma_i^2 \neq \sigma^2 \quad \text{para algún } i$$

Supuesto de varianza constante, Tests de homocedasticidad

Pruebas

- **Levene modificado o test Brown-Forsythe:** robusto a no normalidad y aplicado cuando la varianza de los errores cambia de forma monótona (se incrementa o decrementa) con los niveles de solo una de las variables predictoras.
- **Breusch-Pagan:** postula que $\sigma_i^2 = E[E_i^2] = \sigma^2 h(x_i)$, con la función $h()$ definida de forma que garantice que $\sigma_i^2 > 0$. Algunos de los modelos posibles son:
 - $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$.
 - $\sigma_i^2 = \sigma^2(1 + \gamma x_i)$, ordinariamente se encuentra implementado en paquetes estadísticos.
 - $\sigma_i^2 = \sigma^2(1 + \gamma x_i)^2$, con esta función particularmente se conoce como test de White.

En cualquiera de las versiones se prueba, *bajo la condición de que los errores se distribuyen normal y son incorrelacionados*, $H_0 : \gamma = 0$, vs. $H_1 : \gamma \neq 0$. Note que si $\gamma = 0$, se tendría que $\sigma_i^2 = \sigma^2$.

- **Breusch-Pagan estudentizado:**

Soluciones al problema de “no homogeneidad de varianza”

- Ajuste por mínimos cuadrados ponderados cuando la varianza del error varía de forma sistemática. En este método de ajuste, en la función objetivo de sumas de cuadrados de los errores del modelo, cada uno de ellos es multiplicado por un peso o factor de ponderación ω_i , el cual es inversamente proporcional a la varianza de Y_i .

$$S(\beta) = \sum_{i=1}^n \omega_i E_i^2 = \sum_{i=1}^n \omega_i \left(Y_i - \mathbf{x}_i^T \beta \right)^2, \text{ con } \mathbf{x}_i^T = (1, x_{i1}, \dots, x_{ik}).$$

- Otra posibilidad, es usar transformaciones sobre Y que estabilicen la varianza.
- Un caso particular de transformaciones que estabilizan varianza son las denominadas transformaciones de Box-Cox, las cuales buscan transformar para garantizar tanto varianza constante como la normalidad en la variable respuesta del modelo de regresión.
- Modelos heterocedásticos (pero ya no son modelos lineales).


Supuesto de independencia

- La correlación es una medida de *dependencia lineal* entre dos variables.
- Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;
- Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.
- Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.


Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Supuesto de independencia




(a)




(b)

Figura: (a) $\hat{E}_t$ sin patrón claro; (b) $\hat{E}_t$ vs. $\hat{E}_{t-1}$ con los mismos residuos en (a).

Supuesto de independencia




(a)




(b)

Figura: (a) $\hat{E}_t$ mostrando ciclos; (b) $\hat{E}_t$ vs. $\hat{E}_{t-1}$ con los mismos residuos en (a).

Supuesto de independencia



(a)



(b)

Figura: (a) $\hat{E}_t$ con patrón de rachas de cambio sistemático en signos $\pm$ ó $\mp$; (b) $\hat{E}_t$ vs. $\hat{E}_{t-1}$ con los mismos residuos en (a).

Test Durbin-Watson (DW) para autocorrelación de orden 1

- Diseñado solo para modelos de regresión lineal.
- Para los errores del modelo en el orden del tiempo, E_t , considera modelo autorregresivo de orden 1 (conocido en series de tiempo como AR(1)):

$$E_t = \phi_1 E_{t-1} + a_t, \text{ con } a_t \stackrel{\text{iid}}{\sim} N(0, \sigma_a^2) \text{ y } |\phi_1| < 1.$$

- Bajo este modelo se cumple autocorrelación de orden 1, es:
 $\rho(1) = \text{Corr}(E_t, E_{t-1}) = \phi_1.$

Construcción de la prueba

- 1 Se ajusta el modelo de regresión ordinario.
- 2 Con residuos de ajuste $\hat{E}_t$ en orden de t , se calcula estadístico de prueba d_1 :

$$d_1 = \frac{\sum_{t=2}^n (\hat{E}_t - \hat{E}_{t-1})^2}{\sum_{t=1}^n \hat{E}_t^2} \approx 2(1 - \hat{\rho}(1)), \text{ donde } \hat{\rho}(1) = \frac{\sum_{t=2}^n \hat{E}_t \hat{E}_{t-1}}{\sum_{t=1}^n \hat{E}_t^2},$$

- 3 El juego de hipótesis a considerar se escoge de acuerdo a valores de d_1 : Si $0 < d_1 < 2$, se prueba autocorrelación positiva de orden 1; si $2 < d_1 < 4$, se prueba autocorrelación negativa de orden 1.

Test Durbin-Watson (DW) para autocorrelación de orden 1

Test de auto correlación de orden 1 positiva: Si $0 < d_1 < 2$	
Juego de hipótesis	Criterio de rechazo
$H_0 : \rho(1) = 0$, o equivalentemente $H_0 : \phi_1 = 0$ vs. $H_1 : \rho(1) > 0$, o equivalentemente $H_1 : \phi_1 > 0$	Si $DW_1 < d_1$ es pequeño
Conclusiones posibles: Si no se rechaza H_0 , se concluye que no se ha encontrado evidencia de auto correlación de orden 1; si se rechaza H_0 se concluye que los errores consecutivos (o sea que distan una unidad de tiempo) están positivamente correlacionados.	
Test de auto correlación de orden 1 negativa: Si $2 < d_1 < 4$	
Juego de hipótesis	Criterio de rechazo
$H_0 : \rho(1) = 0$, o equivalentemente $H_0 : \phi_1 = 0$ vs. $H_1 : \rho(1) < 0$, o equivalentemente $H_1 : \phi_1 < 0$	Si $DW_1 > d_1$ es pequeño
Conclusiones posibles: Si no se rechaza H_0 , se concluye que no se ha encontrado evidencia de auto correlación de orden 1; si se rechaza H_0 se concluye que los errores consecutivos (o sea que distan una unidad de tiempo) están negativamente correlacionados.	

¿Qué hacer si no se cumple independencia?

- Trabajar con modelos de regresión con errores correlacionados (errores ARMA estacionarios de media cero).
- Adicionar variables de tendencia en t , de patrón estacional en t (cuando hay patrones periódicos en la variable respuesta).
- Trabajar con primeras diferencias: Suponiendo que $Y_t = \beta_0 + \beta_1 X_t + E_t$ con $E_t = E_{t-1} + u_t$, $u_t \stackrel{iid}{\sim} N(0, \sigma_u^2)$, se considera $Y_t^* = Y_t - Y_{t-1}$ vs. $X_t^* = X_t - X_{t-1}$, y el modelo $Y_t^* = \beta_1^* X_t^* + u_t$ (modelo sin intercepto y término de error u_t) se ajusta por mínimos cuadrados ordinarios, luego de su ajuste se obtienen valores ajustados de Y_t mediante la ecuación, $\hat{Y}_t = \hat{\beta}_0 + \hat{\beta}_1 X_t$, con $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1^* \bar{X}$ y $\hat{\beta}_1 = \hat{\beta}_1^*$.

Supuesto de normalidad

Si los errores son normales, se espera que con la gráfica de probabilidad normal obtenida con los residuos de ajuste, no se encuentren desviaciones significativas con respecto a la recta de probabilidad normal (cuantiles muestrales versus los cuantiles normales), y además que cualquier test de bondad de ajuste distribucional no rechace el supuesto de normalidad.

Tenga en cuenta que:

- Como cualquier test de bondad de ajuste, los tests de normalidad exigen que el conjunto de valores sobre los que se aplican provengan de una muestra aleatoria¹.
- La correlación entre variables en una muestra puede afectar significativamente el desempeño de los tests de bondad de ajuste distribucional.
- El supuesto de independencia debería verificarse antes de la evaluación de normalidad.

¹Recuerde que un conjunto de variables aleatorias, $W_1, W_2, \dots, W_n$, constituyen una muestra aleatoria de tamaño n si y solo si son mutuamente independientes e idénticamente distribuidas.

Supuesto de normalidad

Aunque las pruebas de normalidad se aplican usando los valores de los residuos de ajuste, no debe perder de vista que el supuesto y las conclusiones deben formularse para los errores del modelo:

$$H_0 : E_i \sim N(0, \sigma^2),$$


$$H_1 : E_i \not\sim N(0, \sigma^2).$$

Entre las pruebas de normalidad, la más popular es el test de Shapiro-Wilk el cual compara el estimador varianza basado en estadísticos de orden muestrales vs. el estimador basado en la suma de cuadrados corregidos,


$$W_0 = \frac{\left(\sum_{i=1}^n a_i x_{(i)} \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

con $0 < W_0 < 1$ y los a_i funciones de las medias, varianzas y covarianzas de los estadísticos de orden de v.a $N(0, 1)$.

Supuesto de normalidad



(a)




(b)

Figura: Distribución normal de media cero.

Supuesto de normalidad




(a)




(b)

Figura: Distribución no normal y asimétrica a derecha.

Supuesto de normalidad




(a)




(b)

Figura: Distribución no normal asimétrica a izquierda.

Supuesto de normalidad



(a)



(b)

Figura: Distribución no normal, simétrica pero de colas pesadas.

Soluciones a no normalidad

- La no normalidad frecuentemente va de la mano con la no homogeneidad de la varianza. Una transformación de los valores de Y logra estabilizar la varianza y una aproximación a la normalidad. En estos casos se debe usar primero una transformación que estabilice la varianza y evaluar si el supuesto de normalidad se cumple para los datos transformados. Se tienen las transformaciones de potencia Box-Cox: Y^λ , que comprende la transformación de logaritmo natural (caso $\lambda = 0$).
- Otra solución es trabajar con métodos de regresión no paramétricos.
- Modelos lineales generalizados es otra alternativa pero implica descubrir cuál distribución es la apropiada para la variable respuesta.

Con las transformaciones sobre la variable respuesta existe controversia respecto la escala en la cual debería realizarse las inferencias. Para validación de supuestos y significancia de parámetros debe realizarse en la escala de ajuste, es decir, en la escala transformada. Con relación a la respuesta ajustada o predicha, si la escala transformada no tiene un significado práctico, lo mejor es aplicar la transformación inversa sobre los valores ajustados y predichos en la escala transformada para retornar a la escala original, aunque el resultado da estimaciones sesgadas tanto de la respuesta media como de las predicciones de los valores futuros de la respuesta. Ver al respecto en Kutner et. al., 2005, Sakia, 1992.

Observación atípica u outliers

En la variable Y: Aquella observación que en algún aspecto está separada del resto de los datos y por tanto puede afectar los resultados del ajuste del modelo de regresión. Puede ser:

- Una observación mala (error de registro), entonces puede descartarse.
- Dato extraño que no pueden eliminarse.

Una observación atípica se detecta mediante residuos escalados:

- **Residuales estandarizados** e_i

$$e_i = \frac{\hat{E}_i}{\sqrt{\text{MSE}}}$$

Un e_i grande ($|e_i| > 3$) es indicio de una observación atípica potencial.

- **Residuales estudentizados (internamente estudentizados)** r_i

$$r_i = \frac{\hat{E}_i}{\sqrt{\text{MSE}(1 - h_{ii})}}$$

Con la función de R `rstandard()` se obtiene los residuos estudentizados.

- **Residuos externamente estudentizados** t_i

$$t_i = r_i \left[\frac{n - p - 1}{n - p - r_i^2} \right]^{1/2},$$

p es el número de parámetros del modelo. En R se obtienen con la función `rstudent()`.

Observación atípica u outliers

- Si el MRLS especificado es correcto, los r_i tienen varianza aproximadamente constante igual a 1 independiente de los valores x_i . En conjuntos grandes de datos la varianza de los r_i se puede estabilizar en 1 y así no habrá mucha diferencia entre estos y los e_i .
- Se considera potencialmente atípica aquella observación con r_i grande ($|r_i| > 3$ ó $|r_i| > 2$). Esto también puede aplicarse con los residuos t_i .
- Si todos los supuestos del modelo se cumplen, se espera que aproximadamente el 68 % de los residuales e_i ó r_i , estén entre -1 y +1, aproximadamente el 95 % entre -2 y +2 y aproximadamente 99.7 % entre -3 y +3.
- Muchos outliers en los datos causan niveles de confianza reales menores de lo esperado.
- Tenga en cuenta que también podemos chequear supuestos del modelo usando residuales estandarizados o estudentizados.

Observación atípica u outliers




Figura: Dos observaciones outliers identificadas como valores atípicos en la variable respuesta (a) Gráfico de dispersión y recta ajustada (b) gráfico de probabilidad normal con residuos estudentizados externamente; (c) y (d) gráficos de residuos estudentizados externamente vs x y vs. $\hat{y}$, respectivamente.

- Sakia, R. M. (1992). 'The Box-Cox Transformation Technique: A Review', The Statistician, 41:169–178.
- Kutner, M. H., Natchtsheim, C. J., Neter, J. and Li, W., (2005). Applied Linear Statistical Models, 5th. ed. McGraw-Hill Irwing, NewYork.