

Análisis de regresión

Clase 7

Isabel Ramírez

Universidad Nacional

2026

El modelo de regresión lineal múltiple (MRLM)

Se tiene que Y es la variable respuesta o dependiente de interés, y $X_1, X_2, \dots, X_k$ un conjunto de posibles variables predictoras, independientes, regresoras o covariables.. El modelo de regresión clásico tiene la siguiente estructura (el subíndice i es un identificador del i -ésimo sujeto o unidad de observación):

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + E_i$$

donde:

- E_i es el error aleatorio y $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$.
- $\beta_j, j = 0, 1, \dots, k$: Parámetros de la regresión. β_0 es el intercepto de la función o superficie de regresión y β_j es el coeficiente de regresión asociado a la variable predictora X_j ; también es llamado coeficiente de regresión parcial.

Nomenclatura del MRLM

- $\hat{\beta}_j$: Estimador del parámetro β_j
- $\hat{E}$: Variable aleatoria correspondiendo al residual del modelo ajustado. Su valor observado es denotado por $\hat{\varepsilon}$.
- $\hat{Y}$: Respuesta estimada. Variable aleatoria que representa la estimación de $E[Y|\mathbf{x}]$ con $\mathbf{x} = [X_1, X_2, \dots, X_k]^T$. Su valor observado es denotado por $\hat{y}$.

Características del MRLM

Bajo los supuestos de normalidad, independencia y varianza constante de los errores (Kutner et. al., 2005),

- Y es una variable aleatoria cuyos valores se observan mediante la selección de los valores de las variables predictoras en un espacio de valores de interés.
- Las variables predictoras no son consideradas como variables aleatorias. Sin embargo si esto último no se cumple, el método de mínimos cuadrados ordinarios puede seguir siendo válido si los errores en los valores de las variables X_j son pequeños en comparación con los errores aleatorios.
- Si los datos observados no son una muestra representativa no es apropiado realizar inferencias (extrapolaciones) en un rango de los datos por fuera del considerado.
- El modelo de regresión es lineal en los parámetros.

Características del MRLM

- Los errores aleatorios $E_i \sim N(0, \sigma^2)$, $i = 1, 2, \dots, n$ y además, son estadísticamente independientes. En consecuencia, los valores de la variable respuesta también son estadísticamente independientes y por tanto no correlacionados.
- La varianza de los errores aleatorios es σ^2 , $\forall i, i = 1, 2, \dots, n$ pero desconocida.

El modelo de regresión lineal múltiple (MRLM)

Con estas consideraciones, podemos afirmar que la distribución de la respuesta dadas las predictoras es:

$$Y|X_{i1}, X_{i2}, \dots, X_{ik} \stackrel{\text{ind}}{\sim} N(\beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik}, \sigma^2),$$

donde la respuesta media está dada por

$$E[Y|X_1, X_2, \dots, X_k] = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k,$$

la cual describe a un hiperplano en el espacio de $k + 1$ dimensiones llamado **superficie de regresión o superficie de respuesta**.

Ejemplos de MRLM

- Modelo polinomial de segundo orden en una variable X :

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + E$$

- Modelo de segundo orden en las variables X_1 y X_2 :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_{1,2} X_1 X_2 + \beta_{1,1} X_1^2 + \beta_{2,2} X_2^2 + E$$

- Modelo de primer orden en las variables X_1 , X_2 con término de interacción:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_{1,2} X_1 X_2 + E$$

Significado de los coeficientes de regresión

- β_0 : intercepto de la superficie de respuesta, representará la respuesta media de Y cuando en el conjunto de observaciones sobre las variables predictoras se incluye la coordenada $(X_1, X_2, \dots, X_k) = (0, 0, \dots, 0)$, de lo contrario, si tal coordenada no es observada, entonces β_0 no será interpretable.
- $\beta_j, j = 1, 2, \dots, k$, en un modelo de primer orden: indican el cambio en la respuesta media de Y por unidad de incremento en la respectiva variable X_j , cuando las demás predictoras permanecen constantes. Son denominados **efectos aditivos** o **coeficientes de regresión parcial**.
- Interpretación de coeficientes en modelos con términos lineales, cuadráticos y/o de interacción: Los efectos de una variable X_j sobre la respuesta media, no dependen solo del coeficiente de regresión del término lineal, y además, si dos o más variables tienen efectos de interacción, el efecto de cada una de ellas dependerá de los valores que tomen las otras variables con las que interactúan.

Ejemplo de interpretación de los parámetros

Suponga el siguiente modelo

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + E_i$$

Bajo este modelo, $E[Y|X_1, X_2] = \beta_0 + \beta_1 X_1 + \beta_2 X_2$. Si X_1 se incrementa en una unidad, mientras X_2 está fijo en un valor x_2 cualquiera, entonces el cambio esperado en Y es

$$\Delta E[Y|X_1, X_2] = \beta_1$$

este cambio implica un incremento en la respuesta media si $\beta_1 > 0$, en caso contrario, es una disminución en β_1 unidades, y no depende del valor particular en el que se fijó a X_2 .

Ejemplo de interpretación de los parámetros

Ahora considere el siguiente modelo

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_{1,2} X_1 X_2 + E_i$$

Bajo este modelo, $E[Y|X_1, X_2] = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_{1,2} X_1 X_2$. Si X_1 se incrementa en una unidad, mientras X_2 está fijo en un valor x_2 cualquiera, entonces el cambio esperado en Y es

$$\Delta E[Y|X_1, X_2] = \beta_1 + \beta_{1,2} X_2$$

luego, el efecto que tiene sobre la respuesta media el incremento en una unidad de X_1 , depende no solo de la magnitud y signo de β_1 , sino también de la magnitud y signo de $\beta_{1,2} X_2$, o sea del valor particular en que se fije a X_2 y del coeficiente de interacción $\beta_{1,2}$.

Representación matricial del MRLM

Se tienen observaciones $(x_{i1}, x_{i2}, \dots, x_{ik}, y_i)$, $i = 1, 2, \dots, n$.

Se obtiene un sistema de n ecuaciones con $k + 1$ incógnitas

$$y_1 = \beta_0 + \beta_1 \cdot x_{11} + \beta_2 \cdot x_{12} + \dots + \beta_k \cdot x_{1k} + E_1$$

$$y_2 = \beta_0 + \beta_1 \cdot x_{21} + \beta_2 \cdot x_{22} + \dots + \beta_k \cdot x_{2k} + E_2$$

$$\vdots$$

$$y_n = \beta_0 + \beta_1 \cdot x_{n1} + \beta_2 \cdot x_{n2} + \dots + \beta_k \cdot x_{nk} + E_n$$

Su forma matricial corresponde a: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$,

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}, \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ \vdots \\ E_n \end{bmatrix}.$$

Estimación del MRLM

Estimación por mínimos cuadrados ordinarios (MCO) Minimiza la suma de los cuadrados de los errores,

$$S(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_k x_{ik})]^2 = \sum_{i=1}^n E_i^2.$$

El vector de parámetros estimados es la solución del sistema de ecuaciones normales y es igual a,

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_k \end{bmatrix}_{(k+1) \times 1}$$

desde que $\mathbf{X}^T \mathbf{X}$ sea invertible.

Estimación del MRLM

Estimación de máxima verosimilitud

Puede mostrarse que el método de MCO produce los mejores estimadores lineales insesgados para los parámetros de la superficie de regresión y puede ser usado para la estimación del vector de parámetros del MRLM sin consideraciones distribucionales sobre los errores. Sin embargo, para poder aplicar pruebas de hipótesis y construir intervalos de confianza y otro tipo de inferencias, es necesario realizar y validar tales supuestos. Considerando para los errores del MRLM los supuestos de normalidad, independencia y varianza constante, podemos usar el método de estimación de máxima verosimilitud (MLE) del vector $(\beta, \sigma^2)^T$.

Estimación del MRLM

La función de verosimilitud de $(\beta, \sigma^2)^T$, denotada por $L(\beta, \sigma^2 | \mathbf{y}, \mathbf{x})$ es,

$$\begin{aligned} L(\beta, \sigma^2 | \mathbf{x}, \mathbf{y}) &= f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} \left(y_i - \beta_0 - \sum_{j=1}^k \beta_j x_{ij} \right)^2 \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} S(\beta) \right\}, \end{aligned}$$

Sea $\tilde{\beta}$ el vector de los parámetros que maximiza a $\log L$ con σ^2 fijo,

$$\tilde{\beta} = \hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y},$$

además, la estimación de máxima verosimilitud de la varianza corresponde a,

$$\tilde{\sigma}^2 = \frac{1}{n} S(\hat{\beta}) = \frac{1}{n} (\mathbf{y} - \mathbf{X}\hat{\beta})^T (\mathbf{y} - \mathbf{X}\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2.$$

Respuesta estimada, residuos, estimador de varianza

- La respuesta ajustada es igual a

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \cdots + \hat{\beta}_k x_{ik}$$

- Los residuos son:

$$\hat{\varepsilon}_i = y_i - \hat{y}_i$$

- Bajo el supuesto de $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, el estimador insesgado de la varianza es

$$\hat{\sigma}^2 = \frac{1}{n - k - 1} \sum_{i=1}^n \hat{\varepsilon}_i^2 = \frac{SSE}{n - k - 1} = MSE$$

Propiedades de los estimadores

Bajo los supuestos sobre los errores, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$:

- Los estimadores de MCO corresponden a los estimadores de máxima verosimilitud.
- $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$, satisface las siguientes propiedades:
 - Es un estimador insesgado de β , por lo tanto $E[\hat{\beta}] = \beta$.
 - La matriz de varianzas - covarianzas de $\hat{\beta}$ es $\Sigma_{\hat{\beta}} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$. Un estimador insesgado de esta matriz es, $\hat{\Sigma}_{\hat{\beta}} = \text{MSE} (\mathbf{X}^T \mathbf{X})^{-1}$.

Propiedades de los estimadores

$$\left(\mathbf{X}^T \mathbf{X}\right)^{-1} = \begin{bmatrix} C_{00} & C_{01} & C_{02} & C_{03} & C_{04} \\ C_{01} & C_{11} & C_{12} & C_{13} & C_{14} \\ C_{02} & C_{12} & C_{22} & C_{23} & C_{24} \\ C_{03} & C_{13} & C_{23} & C_{33} & C_{34} \\ C_{04} & C_{14} & C_{24} & C_{34} & C_{44} \end{bmatrix}.$$

Las varianzas de los parámetros estimados pueden denotarse como:

$$\text{Var} \left[\hat{\beta}_j \right] = \sigma^2 C_{jj}, \quad j = 0, 1, 2, \dots, k,$$

El estimador insesgado es,

$$\widehat{\text{Var}} \left[\hat{\beta}_j \right] = \text{MSE } C_{jj},$$

Bajo los supuestos del MRLM se tiene

$$\hat{\beta}_j \sim N \left(\beta_j, \sigma^2 C_{jj} \right), \quad j = 0, 1, \dots, k.$$

Se tiene que σ^2 es desconocida, por lo tanto $T_0 = \frac{\hat{\beta}_j - \beta_j}{\sqrt{\text{MSE } C_{jj}}} \sim t_{n-k-1}$

Inferencias sobre los parámetros - Pruebas de hipótesis

Test bilateral	Estadístico de prueba	Criterio de rechazo
----------------	-----------------------	---------------------

$$H_0 : \beta_j = \beta_{j0}$$

$$H_1 : \beta_j \neq \beta_{j0}$$

$$T_0 = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{\text{MSE } C_{jj}}} \sim t_{n-k-1}$$

con nivel α :

si $|T_0| > t_{\alpha/2, n-k-1}$

con valor P, si:

$$P(|t_{n-k-1}| > |T_0|)$$

es pequeño.

Tests unilaterales	Estadístico de prueba	Criterio de rechazo
--------------------	-----------------------	---------------------

$$H_0 : \beta_j = \beta_{j0}$$

$$H_1 : \beta_j > \beta_{j0}$$

$$T_0 = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{\text{MSE } C_{jj}}} \sim t_{n-k-1}$$

con nivel α :

si $T_0 > t_{\alpha, n-k-1}$

con valor P, si:

$$P(t_{n-k-1} > T_0)$$

es pequeño.

$$H_0 : \beta_j = \beta_{j0}$$

$$H_1 : \beta_j < \beta_{j0}$$

$$T_0 = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{\text{MSE } C_{jj}}} \sim t_{n-k-1}$$

con nivel α :

si $T_0 < -t_{\alpha, n-k-1}$

con valor P, si:

$$P(t_{n-k-1} < T_0)$$

es pequeño.

Inferencias sobre los parámetros - Intervalos de confianza

La estimación por intervalo de confianza al $(1-\alpha)100\%$ es:

$$\hat{\beta}_j \pm t_{\alpha/2, n-k-1} \times \sqrt{\text{MSE } C_{jj}}$$

- Devore, J. L. (2016). Probabilidad y Estadística para Ingeniería y Ciencias, 9a. ed.. Cengage Learning, México.
- Kutner, M. H., Natchtsheim, C. J., Neter, J. and Li, W., (2005). Applied Linear Statistical Models, 5th. ed. McGraw-Hill Irwing, NewYork.