

Análisis de regresión

Clase 8

Isabel Ramírez

Universidad Nacional

2026

Inferencias sobre la respuesta media en el punto

$$\mathbf{x}_0 = (1, x_{01}, x_{0,2}, \dots, x_{0k})^T$$

- Respuesta media estimada en $\mathbf{x}_0$: $\hat{\mu}_{Y|\mathbf{x}_0} = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \hat{\beta}_2 x_{02} + \dots + \hat{\beta}_k x_{0k}$
- Es un estimador insesgado de $\mu_{Y|\mathbf{x}_0}$, por lo tanto

$$E[\hat{\mu}_{Y|\mathbf{x}_0}] = E[\mathbf{x}_0^T \hat{\beta}] = \mathbf{x}_0^T E[\hat{\beta}] = \mathbf{x}_0^T \beta$$
- Su varianza es $\text{Var}[\hat{\mu}_{Y|\mathbf{x}_0}] = \sigma^2 \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0$
- Desde que $\hat{\mu}_{Y|\mathbf{x}_0}$ es una transformación lineal sobre $\hat{\beta}$, entonces

$$\hat{\mu}_{Y|\mathbf{x}_0} \sim N\left(\mathbf{x}_0^T \beta, \sigma^2 \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0\right)$$

- Note que un estimador insesgado de $\text{Var}[\hat{\mu}_{Y|\mathbf{x}_0}]$, es

$$\widehat{\text{Var}}[\hat{\mu}_{Y|\mathbf{x}_0}] = \text{MSE} \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0.$$

Inferencias sobre la respuesta media en el punto

$$\mathbf{x}_0 = (1, x_{01}, x_{02}, \dots, x_{0k})^T$$

Intervalo de confianza de nivel $(1 - \alpha)100\%$ para la respuesta media en el punto $\mathbf{x}_0$,

$$\mathbf{x}_0^T \hat{\boldsymbol{\beta}} \pm t_{\alpha/2, n-k-1} \sqrt{\text{MSE } \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0},$$

Hipótesis H_0	Estadístico de prueba
$H_0: \mu_{Y x_0} = c$	$T_0 = \frac{\mathbf{x}_0^T \hat{\boldsymbol{\beta}} - c}{\sqrt{\text{MSE } \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}} \sim t_{n-k-1}$
Hipótesis H_1	Criterio de rechazo de H_0
$H_1: \mu_{Y x_0} \neq c$	con nivel α : si $ T_0 > t_{\alpha/2, n-k-1}$ con valor P: si $ t_{n-k-1} > T_0 $ es pequeño.
$H_1: \mu_{Y x_0} > c$	con nivel α : si $T_0 > t_{\alpha, n-k-1}$ con valor P: si $t_{n-k-1} > T_0$ es pequeño.
$H_1: \mu_{Y x_0} < c$	con nivel α : si $T_0 < -t_{\alpha, n-k-1}$ con valor P: si $t_{n-k-1} < T_0$ es pequeño.

Inferencias sobre la predicción en el punto

$$\mathbf{x}_0 = (1, x_{01}, x_{02}, \dots, x_{0k})^T$$


- La predicción (respuesta futura) en $\mathbf{x}_0$: $\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \hat{\beta}_2 x_{02} + \dots + \hat{\beta}_k x_{0k}$
- La predicción $\hat{Y}_0$ es estadísticamente independiente de Y_0 , por tanto $\text{Cov}(Y_0, \hat{Y}_0) = 0$
- El error de predicción, $Y_0 - \hat{Y}_0$, cumple que:
 - Su media es cero: $E[Y_0 - \hat{Y}_0] = 0$.
 - Su varianza es $\text{Var}[Y_0 - \hat{Y}_0] = \sigma^2 \left[1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0 \right]$.
 - Su distribución es:

$$Y_0 - \hat{Y}_0 \sim N \left(0, \sigma^2 \left[1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0 \right] \right).$$

- Intervalo de predicción al $(1 - \alpha)100\%$ es,

$$\hat{Y}_0 \pm t_{\alpha/2, n-k-1} \sqrt{\text{MSE} \left[1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0 \right]}$$

Inferencias sobre respuesta media y predicción



Extrapolación oculta

Evitar hacer extrapolaciones (pronósticos) fuera del rango de experimentación en el espacio de la predictoras:


- Por posibles asociaciones entre las X_j , no es suficiente evaluar si cada x_{0j} está dentro del rango usado en su respectiva X_j , debe evaluarse si $\mathbf{x}_0$ pertenece a la región de observación conjunta.
- Los elementos h_{ii} en la diagonal principal de la matriz hat ($\mathbf{H} = \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$) permiten detectar si hay extrapolación oculta.
- Montgomery et. al. (2021): el conjunto de todos los $\mathbf{x}$ que satisfacen

$$\mathbf{x}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x} \leq \max_{i=1,2,\dots,n} h_{ii},$$


es un elipsoide que encierra a todos los puntos que yacen dentro del conjunto convexo más pequeño que contiene a los n puntos originales ($x_{i1}, x_{i2}, \dots, x_{ik}$), $i = 1, 2, \dots, n$, por tanto, para determinar si no se está incurriendo en extrapolación oculta en el punto $\mathbf{x}_0$, basta comprobar si

$$h_{00} = \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0 < \max_{i=1,2,\dots,n} h_{ii},$$

Extrapolación oculta



(a)



(b)

Sumas de cuadrados

- **Suma de cuadrados de residuos (SSE)**

$$\text{SSE} = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \hat{\varepsilon}^T \hat{\varepsilon} = [(I_n - H) \mathbf{y}]^T (I_n - H) \mathbf{y} = \mathbf{y}^T (I_n - H) \mathbf{y}.$$

La SSE es interpretada como *la variabilidad de la respuesta que no es explicada por el modelo de regresión*. Se tiene que

$$\frac{\text{SSE}}{\sigma^2} \sim \chi_{n-k-1}^2.$$

Adicionalmente,

$$E[\text{SSE}] = (n - k - 1) \sigma^2,$$

de modo que un estimador insesgado para σ^2 corresponde a

$$\text{MSE} = \frac{\text{SSE}}{n - k - 1}.$$

El MSE es conocido como la suma de cuadrados medios de residuos

Sumas de cuadrados

- **Suma de cuadrados de totales (SST)**

$$\text{SST} = \sum_{i=1}^n (y_i - \bar{y})^2$$

La SST es definida como la *variabilidad total observada en la variable respuesta*. La SST también es igual a $(n - 1) S_y^2$, donde S_y^2 es la varianza muestral de la variable respuesta, pero típicamente esta varianza es llamada en la regresión como la suma de cuadrados medios totales o MST, es decir,

$$\text{MST} = \frac{\text{SST}}{n - 1} = S_y^2 = \frac{1}{n - 1} \sum_{i=1}^n (y_i - \bar{y})^2.$$

Sumas de cuadrados

- Sumas de cuadrados de la regresión (SSR)

$$\text{SSR} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

La SSR representa la *variabilidad observada en la variable respuesta que es explicada por el modelo de regresión*. Se tiene que

$$\frac{\text{SSR}}{\sigma^2} \sim \chi_{k, \lambda_2}^2 \text{ con } \lambda_2 = \frac{(\mathbf{X}\beta)^T (\mathbf{H} - n^{-1}\mathbf{J}) \mathbf{X}\beta}{\sigma^2}.$$

Al dividir la SSR por sus grados de libertad k se obtiene la denominada suma de cuadrados medios de la regresión ó MSR, es decir

$$\text{MSR} = \frac{\text{SSR}}{k}.$$

Bajo $H_0 : \beta_r = \mathbf{0}$, es decir, $H_0 : \beta_1 = \beta_2 = \cdots \beta_k = 0$, se tiene que $\lambda_2 = 0$.

Descomposición ANOVA de la variabilidad total de la respuesta

La descomposición ANOVA o descomposición de la variabilidad total observada en la respuesta consiste en la siguiente identidad,

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{\text{Variabilidad total (SST)}} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{\text{Variabilidad explicada (SSR)}} + \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{Variabilidad no explicada (SSE)}}$$

En virtud de la anterior igualdad, podemos también establecer la siguiente identidad para los grados de libertad (g.l) de las sumas de cuadrados:

$$\underbrace{\text{g.l (SST)}}_{\text{g.l } n-1} = \underbrace{\text{g.l (SSR)}}_{\text{g.l } k} + \underbrace{\text{g.l (SSE)}}_{\text{g.l } n-k-1}.$$

Test ANOVA: Prueba de la significancia del MRLM

Se evalúa la significancia del MRLM: *si la porción de la variabilidad observada en la respuesta que es explicada por el MRLM es significativa*. Esto es realizado mediante el test ANOVA, el cual propone el siguiente juego de hipótesis:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0;$$

$$H_1 : \beta_j \neq 0, \text{ para al menos un } j, j = 1, 2, \dots, k,$$

Estadístico de prueba

$$F_0 = \frac{\frac{\frac{SSR}{\sigma^2}}{k}}{\frac{\frac{SSE}{\sigma^2}}{n - k - 1}} = \frac{MSR}{MSE} \sim f_{k, n-k-1}.$$

Test ANOVA: Prueba de la significancia del MRLM

Cuadro: Tabla ANOVA del modelo de regresión lineal múltiple

Fuente	SC	g.l	CM	Estadístico F_0	Valor P
Regresión	SSR	k	$MSR = SSR/k$	MSR/MSE	$f_{k, n-k-1} > F_0$
Error	SSE	$n - k - 1$	$MSE = SSE/(n - k - 1)$		
Total	SST	$n - 1$	$MST = SST/(n - 1)$		
Fórmulas					
$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \mathbf{y}^T \left(\mathbf{H} - \frac{1}{n} \mathbf{J} \right) \mathbf{y}, \text{ donde } \mathbf{H} \text{ es la matriz hat.}$ $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \mathbf{y}^T (\mathbf{I} - \mathbf{H}) \mathbf{y}$ $SST = \sum_{i=1}^n (y_i - \bar{y})^2 = \mathbf{y}^T \left(\mathbf{I} - \frac{1}{n} \mathbf{J} \right) \mathbf{y}, \text{ donde } \mathbf{H} \text{ es la matriz hat.}$ Recuerde que: k es el número de predictores en el modelo.					