

Análisis de regresión

Clase 9

Isabel Ramírez

Universidad Nacional

2026

Outliers, puntos de balanceo e influenciales

Además de la validación de supuestos debemos chequear también la presencia de

- Observaciones atípicas
- Puntos de balanceo
- Observaciones influyentes

Observación atípica u outliers

En la variable Y: Aquella observación que en algún aspecto está separada del resto de los datos y por tanto puede afectar los resultados del ajuste del modelo de regresión. Puede ser:

- Una observación mala (error de registro), entonces puede descartarse.
- Dato extraño que no pueden eliminarse.

Una observación atípica se detecta mediante residuos escalados:

- **Residuales estandarizados** e_i

$$e_i = \frac{\hat{E}_i}{\sqrt{\text{MSE}}}$$

Un e_i grande ($|e_i| > 3$) es indicio de una observación atípica potencial.

- **Residuales estudentizados (internamente estudentizados)** r_i

$$r_i = \frac{\hat{E}_i}{\sqrt{\text{MSE}(1 - h_{ii})}}$$

Con la función de R `rstandard( )` se obtiene los residuos estudentizados.

- **Residuos externamente estudentizados** t_i

$$t_i = r_i \left[\frac{n - p - 1}{n - p - r_i^2} \right]^{1/2},$$

p es el número de parámetros del modelo. En R se obtienen con la función `rstudent( )`.

Observación atípica u outliers

- Si el MRL especificado es correcto, los r_i tienen varianza aproximadamente constante igual a 1 independiente del vector $\mathbf{x}_i$. En conjuntos grandes de datos la varianza de los r_i se puede estabilizar en 1 y así no habrá mucha diferencia entre estos y los e_i .
- Se considera potencialmente atípica aquella observación con r_i grande ($|r_i| > 3$ ó $|r_i| > 2$). Esto también puede aplicarse con los residuos t_i .
- Si todos los supuestos del modelo se cumplen, se espera que aproximadamente el 68 % de los residuales e_i ó r_i , estén entre -1 y +1, aproximadamente el 95 % entre -2 y +2 y aproximadamente 99.7 % entre -3 y +3.
- Muchos outliers en los datos causan niveles de confianza reales menores de lo esperado.
- Tenga en cuenta que también podemos chequear supuestos del modelo usando residuales estandarizados o estudentizados.

Observación atípica u outliers






Figura: Dos observaciones outliers identificadas como valores atípicos en la variable respuesta (a) Gráfico de dispersión y recta ajustada (b) gráfico de probabilidad normal con residuos estudentizados externamente; (c) y (d) gráficos de residuos estudentizados externamente vs x y vs. $\hat{y}$, respectivamente.


Punto de balanceo




(a)



(b)



(c)



(d)

Figura: Una observación de balanceo. (a) Gráfico de dispersión y recta ajustada (b) gráfico de probabilidad normal con residuos r_i ; (c) y (d) gráficos de residuos estudentizados internamente vs x y vs. $\hat{y}$, respectivamente.

Punto de balanceo

Es una observación en el espacio de las predictoras, alejada del resto de la muestra y que puede controlar ciertas propiedades del modelo ajustado. Este tipo de observaciones posiblemente no afecte los coeficientes de regresión estimados pero sí los estadísticas de resumen como el R^2 y los errores estándar de los coeficientes estimados.

Son detectados mediante el análisis de los elementos de la diagonal principal de la matriz $\mathbf{H}$, los h_{ii} , que proporcionan una medida estandarizada de la distancia de la i -ésima observación al centro del espacio definido por las predictoras. Los h_{ii} tienen las siguientes propiedades:

- La media de los h_{ii} es

$$\bar{h} = \frac{\sum_{i=1}^n h_{ii}}{n} = \frac{\text{traza}(\mathbf{H})}{n} = \frac{k+1}{n}$$

con k el número de predictoras.

- Observaciones con h_{ii} grandes y residuales r_i también grandes probablemente serán influenciales.

La observación i es un punto de balanceo si $h_{ii} > 2(k+1)/n$, pero si $2(k+1)/n > 1$, este criterio no funciona pues los h_{ii} siempre son menores que 1.

Observaciones influyentes




Figura: Observación influyente, es aquella que tiene un valor moderadamente atípico en la variable explicatoria y en la respuesta, y altera significativamente la estimación de la recta. (a) Gráfico de dispersión y recta ajustada (b) gráfico de probabilidad normal con residuos estudentizados internamente; (c) y (d) gráficos de residuos estudentizados internamente vs x y vs $\hat{y}$, respectivamente.

Observaciones influenciales

Este tipo de observación tiene un impacto notable sobre los coeficientes de regresión ajustados porque jalan al modelo en su dirección. Se caracterizan por tener un valor moderadamente inusual tanto en las predictoras como en la respuesta.

Una observación es influyente si su exclusión causa cambios importantes en la ecuación de regresión ajustada.

Detección: Se construyen medidas basadas en la medición de los efectos de la exclusión de la i -ésima observación:

- Distancia de Cook
- Medida DFBetas
- Medida DFFITS
- Medida COVRATIO

Observaciones influenciales - Notación para pruebas

- $\hat{\mathbf{Y}}_{(i)}$ es el vector de valores estimados sin considerar en el ajuste del modelo a la observación i .
- $\hat{\boldsymbol{\beta}}_{(i)}$ el respectivo vector de parámetros ajustados sin la observación i .
- $\text{MSE}_{(i)}$ es la suma de cuadrados medios del error del modelo ajustado sin la observación i .

Observaciones influenciales - pruebas

Distancia de Cook: Mide la influencia de la observación i sobre todos los valores ajustados de la respuesta, para $i = 1, 2, \dots, n$,

$$D_i = \frac{(\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_{(i)})^T (\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_{(i)})}{(k+1) \text{MSE}} = \frac{(\hat{\boldsymbol{\beta}}_{(i)} - \hat{\boldsymbol{\beta}})^T \mathbf{X}^T \mathbf{X} (\hat{\boldsymbol{\beta}}_{(i)} - \hat{\boldsymbol{\beta}})}{(k+1) \text{MSE}} = \frac{r_i^2}{k+1} \times \frac{h_{ii}}{1 - h_{ii}},$$

- $\frac{h_{ii}}{1 - h_{ii}}$ es el balanceo de la i -ésima observación.
- $D_i \sim f_{k+1, n-k-1}$
- La observación i será influyente si $D_i > 1 \approx f_{0.5, k+1, n-k-1}$.
Esta cota no es muy útil en muestras pequeñas. Otra posibilidad, usada en R en las funciones `influenceIndexPlot()`, `influencePlot()`, es si $D_i > 4/(n - k - 1)$.

Observaciones influenciales - pruebas

DFBetas_{j(i)}: Indica cuánto cambia el j -ésimo coeficiente de regresión estimado $\hat{\beta}_j$ en unidades estándar, si se omite la i -ésima observación,

$$\text{DFBetas}_{j(i)} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sqrt{\text{MSE}_{(i)} C_{jj}}}$$

Una observación será candidata a influyente si $|\text{DFBetas}_{j(i)}| > 2/\sqrt{n}$.

DFFITS_i: Indica cuánto cambia en unidades estándar el valor ajustado si se omite la i -ésima observación,

$$\text{DFFITS}_i = \frac{\hat{Y}_i - \hat{Y}_{(i)}}{\sqrt{\text{MSE}_{(i)} h_{ii}}} = \left(\frac{h_{ii}}{1 - h_{ii}} \right)^{1/2} \frac{\hat{E}_i}{\sqrt{\text{MSE}_{(i)} (1 - h_{ii})}}$$

Una observación será candidata a influyente si $|\text{DFFITS}_{(i)}| > 2\sqrt{\frac{k+1}{n}}$.

Observaciones influenciales - pruebas

COVRATIO_i: Esta medida cuantifica la influencia de la i -ésima observación sobre la matriz de covarianza del vector de parámetros estimados. Corresponde a la razón de los determinantes de las matrices de covarianza de los parámetros estimados cuando la observación i no es considerada, sobre la correspondiente al modelo ajustado con todos los datos.

$$\text{COVRATIO}_i = \frac{\det \left[\text{MSE}_{(i)} \left(\mathbf{X}_{(i)}^T \mathbf{X}_{(i)} \right)^{-1} \right]}{\det \left[\text{MSE} \left(\mathbf{X}^T \mathbf{X} \right)^{-1} \right]} = \left(\frac{\text{MSE}_{(i)}}{\text{MSE}} \right)^{k+1} \times \left(\frac{1}{1 - h_{ii}} \right)$$

- Observaciones con un COVRATIO_i tal que $|\text{COVRATIO}_i - 1| > 3(k+1)/n$, son candidatos a ser influenciales. Sin embargo, el límite inferior de la región de no candidatura a influyente asociado a esta desigualdad, sólo es válido cuando $n > 3(k+1)$, luego solo es recomendado para muestras grandes.
- Tanto los D_i , los DFBetas y los DFFITS se pueden afectar por un error de ajuste grande como por un gran balanceo, por eso, los puntos que sean detectados por estos criterios deben ser investigados.

Medidas de diagnóstico en R

Funciones gráficas

- `infIndexPlot()`: De la librería `car`, para identificar outliers con residuos estudentizados y valores P Bonferroni para prueba de outlier, puntos influenciales con los D_i y de balanceo con los h_{ii} .
- `influenceIndexPlot()`: De la librería `car`. Proporciona los mismos resultados de la función `infIndexPlot()`.
- `influencePlot()`: De la librería `car`, crea un gráfico de burbujas de los residuos estudentizados vs. los h_{ii} . Da límites gráficos para identificación de outliers y de puntos de balanceo y el tamaño de las burbujas es según los D_i .
- `dfbetaPlots()`: De la librería `car`, crea un panel gráfico de los gráficos de dispersión de los DFBetas vs. índice i de las observaciones.
- Funciones en la librería R `olsrr`: `ols_plot_cooks_bar()` y `ls_plot_cooksd_chart()` para diagnósticos con las distancias de Cooks con la posibilidad de especificar entre cinco tipos de valores umbrales: $4/n$ (tipo 1), $4/(n - k - 1)$ (tipo 2), 1 (tipo 3), $1/(n - k - 1)$ (tipo 4) y $3 \times$ promedio de los D_i (tipo 5). También las funciones `ols_plot_dfbetas()` para diagnósticos sobre cada DFBeta, `ols_plot_dffits()` para diagnósticos con los DFFITs, `ols_plot_diagnostics()`, `ols_plot_resid_pot()`, entre otras funciones. Ver documentación de la librería `olsrr`.

Medidas de diagnóstico en R

Funciones que producen valores numéricos de medidas de diagnóstico

- `influence.measures()`: Permite obtener una tabla mostrando las medidas de influencia como los DFBetas (la columna `dfb.1_` corresponde al DFBeta para β_0 , las demás columnas tituladas `dfb.x` corresponden al resto de DFBetas para los coeficientes de regresión parcial en el orden de las variables predictoras en la fórmula R usada en el ajuste), DFFITs, COVRATIOs, los h_{ii} , en cada una de las observaciones, colocando una indicación (*) en la fila de las observaciones que resulten influyentes por alguna de estas medidas.
- Otras funciones: Permiten extraer por separado los diferentes tipos de medidas de diagnósticos: `rstudent()`, `rstandar()`, `dffits()`, `dfbetas()`, `covratio()`, `cooks.distance()`, `hatvalues()`, `hat()`.