

Análisis de regresión

Clase 10

Isabel Ramírez

Universidad Nacional

2026

Sumas de cuadrados extra

Una suma de cuadrados extra mide la reducción marginal en la SSE cuando una o varias variables explicatorias son agregadas al modelo de regresión, dado que otros predictores están en el modelo, o bien, es una medida del incremento marginal en la SSR cuando uno o más predictores son agregados al modelo de regresión (Kutner et. al., 2005).

Suponga un MRLM sobre $k = 3$ predictores, Modelo Completo (**MF**) es

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + E_i,$$

- La suma de cuadrados extra de X_1 dado que X_2 y X_3 ya están en el modelo:

$$SSR(X_1|X_2, X_3) = SSR(X_1, X_2, X_3) - SSR(X_2, X_3) =$$

$$SSE(X_2, X_3) - SSE(X_1, X_2, X_3).$$
- $SSR(X_1|X_2, X_3)$ se interpreta como el incremento marginal en la suma de cuadrados de regresión (o la disminución en la suma de cuadrados de residuales) por agregar X_1 al modelo de regresión múltiple de Y vs. X_2 y X_3 .

Sumas de cuadrados extra

- El modelo reducido (**MR**) es

$$Y_i = \beta_0 + \beta_2 X_{i2} + \beta_3 X_{i3} + E_i.$$

- Los grados de libertad de $\text{SSR}(X_1|X_2, X_3)$ se hallan como la diferencia de los grados de libertad de $\text{SSR}(X_1, X_2, X_3)$ menos los grados de libertad de $\text{SSR}(X_2, X_3)$, es decir, $3 - 2 = 1$.

Descomposición de la SSR en sumas de cuadrados extras

Considere el modelo de regresión múltiple de una respuesta dada sobre tres variables, X_1, X_2, X_3 . Algunas posibles descomposiciones de las $SSR(X_1, X_2, X_3)$

$$SSR(X_1, X_2, X_3) = SSR(X_1) + SSR(X_2|X_1) + SSR(X_3|X_1, X_2)$$

$$SSR(X_1, X_2, X_3) = SSR(X_2) + SSR(X_3|X_2) + SSR(X_1|X_2, X_3)$$

$$SSR(X_1, X_2, X_3) = SSR(X_2) + SSR(X_1, X_3|X_2)$$

$$SSR(X_1, X_2, X_3) = SSR(X_1, X_2) + SSR(X_3|X_1, X_2)$$

Sumas de cuadrados secuenciales ó SS1 (tipo 1)

Sumas de cuadrados extras de 1 grado de libertad, en la cual *cada variable explicatoria es agregada secuencialmente, según el orden en que son nombradas en el MF*. Por ejemplo, si se especifica el modelo

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + E_i \quad E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Las sumas de cuadrados secuenciales son:

Fuente	SS1	g.l.	F_0	Valor P asociado
X_1	$\text{SSR}(X_1)$	1	$\frac{\text{SSR}(X_1)}{\text{MSE}(X_1, X_2, \dots, X_k)}$	$f_{1, n-k-1} > F_0$
$X_2 X_1$	$\text{SSR}(X_2 X_1)$	1	$\frac{\text{SSR}(X_2 X_1)}{\text{MSE}(X_1, X_2, \dots, X_k)}$	$f_{1, n-k-1} > F_0$
$X_3 X_1, X_2$	$\text{SSR}(X_3 X_1, X_2)$	1	$\frac{\text{SSR}(X_3 X_1, X_2)}{\text{MSE}(X_1, X_2, X_3)}$	$f_{1, n-k-1} > F_0$
Modelo	$\text{SSR}(X_1, X_2, X_3)$	3	$\frac{\text{SSR}(X_1, X_2, X_3)/3}{\text{MSE}(X_1, X_2, X_3)}$	$f_{3, n-k-1} > F_0$

En R usamos `anova(modelo)`, para obtener estas suma de cuadrados SS1.

Sumas de cuadrados parciales ó SS2 (tipo 2)

Se refiere a las sumas de cuadrados extras de cada variable explicatoria en el modelo, dadas las demás. Por ejemplo, si se especifica el modelo

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + E_i \quad E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Las sumas de cuadrados parciales son:

Fuente	SS2(X_j)	Grados de libertad	F_0	Valor P
$X_1 X_2, X_3$	$\text{SSR}(X_1 X_2, X_3)$	1	$\frac{\text{SSR}(X_1 X_2, X_3)}{\text{MSE}(X_1, X_2, X_3)}$	$f_{1, n-k-1} > F_0$
$X_2 X_1, X_3$	$\text{SSR}(X_2 X_1, X_3)$	1	$\frac{\text{SSR}(X_2 X_1, X_3)}{\text{MSE}(X_1, X_2, X_3)}$	$f_{1, n-k-1} > F_0$
$X_3 X_1, X_2$	$\text{SSR}(X_3 X_1, X_2)$	1	$\frac{\text{SSR}(X_3 X_1, X_2)}{\text{MSE}(X_1, X_2, X_3)}$	$f_{1, n-k-1} > F_0$
MSE(X_1, X_2, X_3) es el MSE del MRLM de Y vs. X_1, X_2, X_3				

En R usamos la función `Anova(modelo)` de la librería `car`, para las sumas SS2.

Las sumas de cuadrados extras tipo SS2 no constituyen una descomposición de la suma de cuadrados de la regresión del MF, es decir, la suma de las sumas de cuadrado tipo SS2 no es igual al SSR del MF, en cambio las sumas de cuadrados extras tipo SS1 sí son una descomposición de la suma de cuadrados de la regresión del MF. Por ejemplo, en un MRLM con las variables predictoras X_1, X_2, X_3 ,

$$\text{SSR}(X_1, X_2, X_3) \neq \underbrace{\text{SSR}(X_1|X_2, X_3) + \text{SSR}(X_2|X_1, X_3) + \text{SSR}(X_3|X_1, X_2)}_{\text{Sumas de cuadrados tipo 2 ó SS2}}$$

En cambio,

$$\text{SSR}(X_1, X_2, X_3) = \underbrace{\text{SSR}(X_1) + \text{SSR}(X_2|X_1) + \text{SSR}(X_3|X_1, X_2)}_{\text{Sumas de cuadrados tipo 1 ó SS1}}.$$

Pruebas de significancia individual de los β_j ($j = 1, \dots, k$) con sumas de cuadrados extra

Suponga un MRLM con k predictoras y nos interesan la hipótesis de la forma

$$H_0 : \beta_j = 0 \text{ vs. } H_1 : \beta_j \neq 0$$

El test F usando la SS2 asociada a X_j , tiene estadístico de prueba:

$$F_{0j} = \frac{\text{SSR}(X_j | X_1, X_2, \dots, X_{j-1}, X_{j+1}, \dots, X_k)}{\text{MSE}(X_1, X_2, \dots, X_{j-1}, X_j, X_{j+1}, \dots, X_k)},$$

Bajo H_0 y $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$

- $F_{0j} \sim f_{1, n-k-1}$
- En el test Anova para cada variable X_j ,

$$F_{0j} = \frac{\text{SC}_j}{\text{MSE}} = \frac{\hat{\beta}_j^2 / C_{jj}}{\text{MSE}} = T_{0j}^2.$$

$$\text{donde } T_{0j} = \frac{\hat{\beta}_j}{\sqrt{C_{jj} \text{MSE}}} \sim t_{n-k-1}$$

Pruebas de significancia simultánea sobre subconjuntos de coeficientes de regresión

Sea el MRLM con k predictores $X_1, X_2, \dots, X_k$, bajo el supuesto de errores $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Para un subconjunto de r de las k variables predictoras, $X_{i_1}, X_{i_2}, \dots, X_{i_r}$, queremos probar si son significativas conjuntamente en el modelo en presencia de las demás X 's,

$$H_0 : \beta_{i_1} = \beta_{i_2} = \dots = \beta_{i_r} = 0$$

$$H_1 : \beta_j \neq 0, \text{ para al menos un } j, j \in i_1, i_2, \dots, i_r$$

El estadístico de prueba es de la forma:

$$F_0 = \frac{[\text{SSE}_{(\text{MR})} - \text{SSE}_{(\text{MF})}] / r}{\text{MSE}_{(\text{MF})}} = \frac{[\text{SSR}_{(\text{MF})} - \text{SSR}_{(\text{MR})}] / r}{\text{MSE}_{(\text{MF})}},$$

con

- $r = \text{gl}(\text{SSE}_{(\text{MR})}) - \text{gl}(\text{SSE}_{(\text{MF})})$, o bien, $r = \text{gl}(\text{SSR}_{(\text{MF})}) - \text{gl}(\text{SSR}_{(\text{MR})})$
- $\text{SSE}_{(\text{MR})}$ es el SSE del **(MR)** bajo H_0 , es decir,

$$\text{SSE}_{(\text{MR})} = \text{SSE}(X_j \text{ tales que } X_j \neq X_{i_1}, X_{i_2}, \dots, X_{i_r}),$$

cuyos $\text{gl}(\text{SSE}_{(\text{MR})}) = n - (k - r) - 1$.

- $\text{SSE}_{(\text{MF})}$ es el SSE del modelo completo **(MF)** con todas las k variables X_j , o sea,

$$\text{SSE}_{(\text{MF})} = \text{SSE}(X_1, \dots, X_k),$$

con $\text{gl}(\text{SSE}_{(\text{MF})}) = n - k - 1$. La diferencia de los g.l. entre los dos SSE's es $[n - (k - r) - 1] - [n - k - 1] = r$.

- Para los modelos MR y MF las sumas de regresión son respectivamente, $\text{SSR}_{(\text{MR})}$ y $\text{SSR}_{(\text{MF})}$, en tanto que sus grados de libertad son $k - r$ y k .

Pruebas de significancia simultánea sobre subconjuntos de coeficientes de regresión

También se puede escribir al estadístico F_0 como,

$$F_0 = \frac{[\text{SSE}(X_j \text{ tales que } X_j \neq X_{i_1}, X_{i_2}, \dots, X_{i_r}) - \text{SSE}(X_1, \dots, X_k)] / r}{\text{MSE}(X_1, \dots, X_k)},$$

Donde el numerador representa la siguiente suma de cuadrados extra:

$$\begin{aligned} \text{SSR}(X_{i_1}, X_{i_2}, \dots, X_{i_r} | X_j \text{ tales que } X_j \neq X_{i_1}, X_{i_2}, \dots, X_{i_r}) = \\ \text{SSE}(X_j \text{ tales que } X_j \neq X_{i_1}, X_{i_2}, \dots, X_{i_r}) - \text{SSE}(X_1, \dots, X_k), \end{aligned}$$

por tanto también F_0 puede escribirse como,

$$F_0 = \frac{\text{SSR}(X_{i_1}, X_{i_2}, \dots, X_{i_r} | X_j \text{ tales que } X_j \neq X_{i_1}, X_{i_2}, \dots, X_{i_r}) / r}{\text{MSE}(X_1, \dots, X_k)}$$

- 1 Puede demostrarse que bajo H_0 y supuestos $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, $F_0 \sim f_{r, n-k-1}$
- 2 Se rechaza H_0 ,
 - si $F_0 > f_{\alpha, r, n-k-1}$ a un nivel de significancia α , o bien,
 - si $f_{r, n-k-1} > F_0$ es pequeño.