

Análisis de regresión

Clase 12

Isabel Ramírez

Universidad Nacional

2026

Comparación de efectos parciales de las variables

Sea,

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik} + E_i$$

- Si las X_j tienen diferente escala de medida, no podemos determinar cuál de ellas tiene mayor o menor efecto parcial sobre la respuesta media.
- Para comparar los coeficientes de regresión se escalonan todas las variables (Y y las X_j).

Escalamiento normal unitario:

$$Y_i^* = \frac{Y_i - \bar{Y}}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2}}, \quad X_{ij}^* = \frac{X_{ij} - \bar{X}_j}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2}}, \quad j = 1, \dots, k$$

Modelo con coeficientes de regresión estandarizados β_j^* :

$$Y_i^* = \beta_1^* X_{i1}^* + \beta_2^* X_{i2}^* + \cdots + \beta_k^* X_{ik}^* + E_i^*$$

β_j^* : Efecto medio de X_j (en unidades estándar) dado que las demás variables explicatorias están en el modelo. Su magnitud permite determinar la importancia relativa de X_j en presencia de las demás variables.

Multicolinealidad

Existencia de dependencia lineal casi perfecta entre dos o más variables explicatorias en el MRLM. Si existiera dependencia lineal exacta entre dos o más variables explicatorias, la matrix $\mathbf{X}^T \mathbf{X}$ sería singular (no invertible) y por tanto no podríamos hallar los estimadores de mínimos cuadrados.

Posibles causas (Montgomery et. al., 2012)

- El método de recolección de los datos
- Restricciones en el modelo o la población
- Especificación del modelo
- Un modelo sobre especificado (más variables que observaciones)

Efectos de la multicolinealidad

- **Inflación de las varianzas de los estimadores:** Medida por los VIFs,

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

con R_j^2 el R^2 de la regresión de X_j sobre el resto de predictoras.

Los VIFs son funciones de los inversos de los valores propios λ_j de $\mathbf{X}^T \mathbf{X}$, por lo que valores pequeños en algún λ_j infla la varianza de los estimadores.

- $\hat{\beta}_j$ muy grandes en términos absolutos: Debido a que $\text{traza}(\mathbf{X}^T \mathbf{X})^{-1} = \sum_{j=1}^{k+1} \frac{1}{\lambda_j}$, resulta grande.
- $\hat{\beta}_j$ con signos contrarios a lo esperado: La inflación de varianza causa mayor dispersión alrededor del verdadero parámetro dando la oportunidad de valores estimados con signos contrarios a lo esperado.
- Cuando hay multicolinealidad grave el modelo de regresión ajustado es significativo (según prueba F de la ANOVA) mas individualmente, ninguno de los β_j asociados a las variables explicatorias resulta significativo (según pruebas t de la significancia individual).

Diagnóstico de la multicolinealidad

- **Examen de la matriz de correlación:** Útil cuando no intervienen más de dos variables en una asociación lineal.
- **Factores de inflación de varianza:** Si $VIF_j > 10$, hay problemas serios de multicolinealidad.
- **Análisis de los valores propios λ_j de $X^T X$:**
 - ① **Número de condición:** $\kappa = \lambda_{\max} / \lambda_{\min}$
 - ① Si $\sqrt{\kappa} < 10$, no hay problemas serios de multicolinealidad.
 - ② Si $10 \leq \sqrt{\kappa} \leq 31$, la multicolinealidad es moderada.
 - ③ Si $\sqrt{\kappa} > 31$, la multicolinealidad es grave.
 - ② **Índices de condición:** $\kappa = \lambda_{\max} / \lambda_j$
 - ① Si $\sqrt{\kappa} < 10$, para todo j , no hay problemas serios de multicolinealidad.
 - ② Si al menos para un j $10 \leq \sqrt{\kappa} \leq 31$, la multicolinealidad es moderada.
 - ③ Si al menos para un j $\sqrt{\kappa} > 31$, la multicolinealidad es grave (por lo menos hay una asociación casi lineal entre dos o más variables explicatorias).
 - ③ **Las proporciones de descomposición de varianza, π_{ij} :** Proporción en la que λ_j aporta a la varianza de β_j . $\pi_{ij} > 0.5$ para dos o más coeficientes de regresión asociados con un mismo λ_j pequeño, es evidencia de multicolinealidad entre las variables correspondientes a tales coeficientes.

Multicolinealidad

Hay controversia acerca de si los datos deben “centrarse” (restarles sus respectivas medias a los valores de cada variable) para diagnosticar multicolinealidad usando el criterio de los valores propios o de las proporciones de la descomposición de varianzas. Si se centran los datos se elimina el mal condicionamiento debido al intercepto del modelo. Si este parámetro no tiene interpretación física, se recomienda trabajar sobre los datos centrados. Si por el contrario el intercepto es interpretable, no se recomienda centrar los datos (Montgomery et. al., 2021).

Funciones R: En la librería `car`, encontramos la función `vif()`; en la librería `olsrr`, se cuenta con la función `ols_coll_diag()`, que proporciona, los VIFs, la tolerancias ($1-R_j^2$, con R_j^2 el R^2 de la regresión de X_j vs. las otras predictoras, y se interpreta como la proporción de la variabilidad en X_j que no puede ser explicada por las otras predictoras) los índices de condición y la proporciones de descomposición de varianza. Con la función de usuario `multicolin()` se puede obtener lo anterior tanto con los datos centrados como no centrados.

Métodos de selección de variables

En algunos estudios observacionales o exploratorios, se parte de un modelo de regresión en el que se considera un conjunto grande de variables explicatorias candidatas para luego identificar un subconjunto entre tales variables, que resulte potencialmente útil para construir el modelo de regresión final. Dependiendo de los usos que se deseen dar a un modelo de regresión variará el subconjunto de variables seleccionadas. Por ejemplo, desde el punto de vista del ajuste, cierto subgrupo de variables serán útiles, en tanto que desde el punto de vista del pronóstico, otro subconjunto podría resultar ser mejor.

Métodos de selección de variables, todas la regresiones posibles

Este procedimiento consiste en correr las regresiones de la variable respuesta vs. todos los posibles subconjuntos de $1, 2, \dots, k$, variables explicatorias

- R_{adj}^2 : Modelo con mayor valor en este estadístico.
- **MSE**: Modelo con menor valor en este estadístico.
- C_p : Donde p es el número de parámetros incluyendo β_0 , es una medida del sesgo en el modelo de regresión, es decir, de $E[\hat{Y}_i] - \mu_{Y|X_i}$. El mejor modelo es aquél para el cual C_p es el más pequeño posible y tal que la diferencia $|C_p - p|$ es mínima. Este estadístico se calcula como

$$C_p = \frac{\text{SSE}_p}{\text{MSE}(X_1, \dots, X_k)} - (n - 2p)$$

- **PRESS_p**: Modelo con menor valor en este estadístico.

$$\text{PRESS}_p = \sum_{i=1}^n e_{(i)}^2 = \sum_{i=1}^n \left(Y_i - \hat{Y}_{i(i)} \right)^2 = \sum_{i=1}^n \frac{\hat{E}_i^2}{(1 - h_{ii})^2}$$

Métodos de selección de variables, selección automática

Forward o selección hacia adelante: Agrega secuencialmente variables, de a una variable por vez, a un nivel de significancia α_{in} .

- 1 Ajustar todos los MRL simple. A un nivel de significancia α_{in} ingresa primero aquella X_j estadísticamente significativa que conduzca al menor MSE.
- 2 Continuar agregando variables, una por vez, tal que la variable candidata a ingresar en un paso dado, reduzca significativamente el SSE en presencia de las que ya están en el modelo (test F de la significancia de la variable candidata dadas las X 's previamente ingresadas, con nivel de significancia α_{in}).
- 3 Entre varias X 's candidatas a ingresar al modelo en un paso dado del algoritmo, elegir aquella que reduzca más significativamente el SSE.
- 4 Parar cuando entre las X 's que no han sido ingresadas en los pasos previos, ninguna contribuye significativamente en la reducción del SSE a un nivel de significancia α_{in} , en presencia de las que ya están en el modelo.

Métodos de selección de variables, selección automática

Backward o selección hacia atrás: Del modelo completo elimina secuencialmente de a una variable por vez, a un nivel de significancia α_{out} .

- 1 Ajustar modelo con todas las variables. Calcular valores P para la significancia de cada variable.
- 2 A un nivel de significancia α_{out} , eliminar secuencialmente de a una variable buscando reducir significativamente el SSE. Las X 's candidatas a salir del modelo en un paso dado son aquellas estadísticamente no significativas en presencia de las demás (test F de significancia individual o test t).
- 3 Entre varias X_j candidatas a salir en cada paso, elegir la menos significativa en presencia de las demás X 's que están en el MRLM que se tenga en ese momento.
- 4 Parar proceso cuando todas las X 's que aún permanecen en el modelo son significativas a un nivel de significancia α_{out} .

Métodos de selección de variables, selección automática

Stepwise: Una combinación de los dos anteriores (paso forward inmediatamente seguido de un paso backward). Puede aplicarse con $\alpha_{in} \neq \alpha_{out}$.

- 1 Comenzar agregando variables, una a la vez, según el método forward a un nivel de significancia α_{in} .
- 2 Una vez ingresada una nueva variable, evaluar que las demás que ya estaban en el modelo sigan siendo significativas, es decir, aplicar el principio del método backward a un nivel de significancia α_{out} .
- 3 En un paso dado puede ingresar una variable y salir otra que previamente ya había sido ingresada (puede suceder que una misma variable entre, salga y vuelva a ser ingresada en pasos subsiguientes del algoritmo).
- 4 Parar proceso cuando ya no hay más variables para ingresar que contribuyan significativamente a reducir el SSE, en tanto que todas las que se tienen en el modelo son significativas.